

《交通大数据技术》复习试卷第七套

根据第 1-6 章课件与课程总结整理

姓名 _____ 学号 _____
班级 _____ 成绩 _____

考试说明：本试卷满分 100 分。选择题 20 题，每题 2 分；判断题 10 题，每题 2 分；简答题 3 题，每题 8 分；综合应用题 1 题，16 分。

一、选择题（每题 2 分，共 40 分）

1. 路网 GIS 底图、公交线路站点表通常变化较慢，而车辆 GPS 位置流持续快速变化。按数据产生与变化频率分类，前者与后者更接近（ ）。
A. 结构化数据与非结构化数据
B. 图像数据与音频数据
C. 静态或准静态数据与动态或实时数据
D. 公钥数据与私钥数据
2. 把不同来源的道路编号、站点编码、时间粒度和坐标系统一到同一标准，主要属于 ETL 中的（ ）。
A. 抽取
B. 转换
C. 加载
D. 签名
3. 大数据 4V 特征中的 Value 在交通场景中更强调（ ）。
A. 单个文件必须非常大
B. 数据格式必须完全一致
C. 数据只能实时产生，不能保存历史
D. 通过分析挖掘支撑拥堵治理、预测预警和出行服务

4. 某交通管理部门自建私有云保存敏感业务数据，同时调用公有云地图、短信和 AI 服务，这种部署形态更接近（ ）。
- A. 只属于公有云
 - B. 只属于私有云
 - C. 混合云
 - D. 工作量证明
5. 云平台向开发者提供数据库、消息队列、运行环境和部署能力，开发者在其上开发交通应用，这更接近（ ）。
- A. IaaS
 - B. PaaS
 - C. SaaS
 - D. POW
6. 在物联网典型架构中，设备管理、数据管理、计算分析和支撑通常更接近（ ）。
- A. 感知层
 - B. 网络层
 - C. 平台层
 - D. 共识层
7. 隧道入口摄像头在本地边缘节点识别异常停车并立即联动警示屏，主要体现边缘计算的（ ）。
- A. 强制所有数据回传中心云
 - B. 低时延响应和减少网络回传压力
 - C. 只能离线保存纸质报表
 - D. 取消传感器采集
8. 对无标签的车辆轨迹进行聚类，从中发现通勤、旅游、货运等出行模式，主要属于（ ）。
- A. 监督学习
 - B. 无监督学习
 - C. 强化学习
 - D. 数据加载
9. 在交通知识图谱中，道路、站点、车辆、事件可作为对象，“连接”、“经过”、“发生于”可作为关联，限速、经纬度可作为描述信息。这体现知识图谱主要包含（ ）。

- A. 实体、关系和属性
 - B. Block、Split 和 Shuffle
 - C. 公钥、私钥和随机数
 - D. URL、HTML 和 CSS
10. 多个单位共享事故处置记录时，希望记录可追溯、不易被单方篡改，并能进行跨机构可信协同，较适合引入（ ）。
- A. 图片压缩
 - B. 三维饼图
 - C. 单机文本文件
 - D. 区块链或分布式账本机制
11. 实时交通事件流同时被指挥调度、公众诱导和统计分析系统使用，采用发布-订阅模式的主要好处是（ ）。
- A. 解耦生产者与多个消费者，便于实时分发和扩展
 - B. 保证所有系统只能手工复制数据
 - C. 使数据不能被任何系统读取
 - D. 自动生成私钥和公钥
12. 需要提交查询表单或选择条件后才能访问的交通违法查询、票务查询等网页，更适合由（ ）关注。
- A. 通用网络爬虫
 - B. 聚焦网络爬虫
 - C. 增量式网络爬虫
 - D. 深层网络爬虫
13. 对事故发生时段的少量关键速度数据出现缺失，较合理的处理思路是（ ）。
- A. 一律删除整天数据
 - B. 不看业务含义，全部填 0
 - C. 结合业务含义选择估算填补、保留标记或谨慎删除
 - D. 将缺失值改成私钥
14. 对车牌、手机号、支付账号等敏感字段脱敏时，同一真实对象在不同表中应尽量映射为同一脱敏值，这主要体现（ ）。
- A. 数据越乱越安全

- B. 删除所有关联关系
 - C. 脱敏前后关联性和多次脱敏一致性
 - D. 只追求字段长度变短
15. RAG 被归入 Context Engineering 的原因主要是 ()。
- A. 它只负责调整字体颜色
 - B. 它检索相关外部知识, 并把结果组织为大模型上下文
 - C. 它完全不需要知识库、索引和检索
 - D. 它用工作量证明替代文本生成
16. Agent 分阶段实现自我修正的较合理顺序是 ()。
- A. 初始生成、自我反馈、针对性修正、循环迭代
 - B. 加载、签名、上链、删除
 - C. 绘图、配色、打印、归档
 - D. 分箱、验签、降噪、出块
17. HDFS 引入数据块和副本机制的主要意义是 ()。
- A. 支持大文件分布式存储, 并通过多副本提高容错性
 - B. 让所有文件只能保存在 NameNode 上
 - C. 强制每个文件只能小于 1KB
 - D. 取消客户端读取数据的能力
18. 关于 HDFS Block 与 MapReduce Split, 下列说法较准确的是 ()。
- A. 二者完全相同, 都是私钥
 - B. Block 面向可视化, Split 面向区块链
 - C. Block 是物理存储单位, Split 是逻辑输入分片
 - D. Split 只能用于保存 FsImage
19. Spark 应用中, 运行在工作节点上、负责执行 Task 并可缓存数据的进程通常是 ()。
- A. NameNode
 - B. Executor
 - C. Reducer
 - D. 私钥
20. 某图表中实际交通流量只增长 20%, 但柱形高度被绘制成增长数倍, 导致读者误判。这主要违背了 ()。

- A. 数据脱敏一致性
- B. 可视化准确表达原则和 Lie Factor 控制
- C. HDFS 多副本机制
- D. 发布-订阅主题划分

二、判断题（每题 2 分，共 20 分）

1. 数据仓库通常面向主题、集成历史数据并支持分析决策，而不是主要承担高频事务增删改。（ ）
2. 大数据中的 Variety 只表示数据量很大，与数据类型和来源是否多样无关。（ ）
3. 物联网系统一旦使用边缘计算，就完全不再需要云端平台和中心存储。（ ）
4. 中心云与边缘节点可以协同工作：边缘负责低时延处理，云端负责全局存储、训练和分析。（ ）
5. 在非对称密码体系中，私钥应妥善保密，公钥通常可以公开用于验签或加密。（ ）
6. 聚焦网络爬虫通常围绕预设主题筛选和抓取相关网页。（ ）
7. 异常值可能代表真实特殊交通事件，处理前需要结合业务背景判断。（ ）
8. 数据脱敏只要把敏感字段随机打乱即可，不需要保持统计特征、业务规则或跨表关联。（ ）
9. RAG 可以通过引入外部检索结果，为大模型回答提供更可靠的上下文依据。（ ）
10. Spark 是 Hadoop MapReduce 的简单改名，必须完全依赖 Hadoop 才能运行。（ ）

三、简答题（每题 8 分，共 24 分）

1. 简述发布-订阅模式在实时交通数据接入中的作用，并比较它与批量 ETL 接入在适用场景上的差异。
2. 简述数据脱敏的基本原则和常见方法，并结合车牌、乘客支付记录或轨迹数据说明脱敏时需要注意的问题。
3. 简述 Spark 的基本思想、主要组件及其相对 Hadoop MapReduce 更适合迭代式交通分析任务的原因。

四、综合应用题（16 分）

1. 某市希望利用公交 GPS、路侧地磁和雷达检测器、ETC 通行记录、路网 GIS 与天气数据，制作早晚高峰交通运行分析报表。请结合课程总结中“数据使用流程、数据采集、ETL、缺失值和异常值处理、HDFS/MapReduce/Spark、数据可视化原则”等内容，回答：（1）这些数据分别可以看作哪些类型或来源，哪些更适合实时接入，哪些更适合批量 ETL；（2）清洗转换阶段应如何处理缺失值、异常值，并统一时间、空间和路段编码；（3）海量历史数据可利用 HDFS、MapReduce 或 Spark 进行存储和分析；（4）最终报表可采用哪些可视化方式，并说明如何体现“信、达、雅”或准确、高效、美观的原则。

参考答案与评分要点

一、选择题

1	2	3	4	5	6	7	8	9	10
C	B	D	C	B	C	B	B	A	D

11	12	13	14	15	16	17	18	19	20
A	D	C	C	B	A	A	C	B	B

二、判断题

1	2	3	4	5	6	7	8	9	10
对	错	错	对	对	对	对	错	对	错

三、简答题参考要点

1. 发布-订阅模式中，生产者把车辆位置、交通事件、设备告警等实时消息发布到主题，消费者按需订阅并处理消息，可实现系统解耦、削峰缓存、多消费者分发和实时扩展。它适合公交 GPS、网约车轨迹、路况事件、设备状态等连续流数据。批量 ETL 更适合历史收费记录、日终业务表、周期性统计报表等离线或准离线数据接入，重点是抽取、清洗转换和加载到数据仓库。发布-订阅作用 4 分，适用场景 2 分，与批量 ETL 对比 2 分。
2. 数据脱敏原则包括保持必要统计特征、保持字段和业务规则关联、保持跨表一致性、保持多次脱敏一致性，并遵循最小化使用和权限控制。常见方法包括数据替换、无效化、随机化、灵活编码、泛化聚合，也可使用生成式方法构造模拟数据。车牌可做一致性替换或部分遮蔽，支付账号和手机号应去标识化或替换，轨迹数据要防止通过精细时空点重识别，可做空间网格化、时间降采样、聚合发布或敏感点模糊。原则 3 分，方法 2 分，交通隐私例子与注意事项 3 分。
3. Spark 的基本思想是基于内存计算和 DAG 调度组织分布式任务，尽量减少迭代过程中反复读写磁盘的开销。主要组件包括 Driver、Cluster Manager、Executor、Task 和 Application；Driver 负责创建上下文、生成和调度任务，Executor 在工作节点执行 Task 并缓存数据，Cluster Manager 负责资源管理。相对 Hadoop MapReduce，Spark 计算模式更灵活，适合机器学习、轨迹聚类、短时拥堵预测、交互式查询和流批结合等需要多轮迭代或较低延迟的交通分析任务。基本思想 2 分，组件 3 分，优势和交通例子 3 分。

四、综合应用题参考要点

1. 可从以下方面作答：

(1) 数据类型与接入：公交 GPS 属于动态或实时轨迹数据，地磁和雷达属于交通感知设备数据，ETC 通行记录属于结构化业务记录，路网 GIS 属于静态或准静态空间基础数据，天气属于外部环境数据；公交 GPS、地磁和雷达速度流更适合实时或准实时接入，ETC 历史记录、路网 GIS 和历史天气数据更适合批量 ETL 接入。(4 分)

(2) 清洗转换：缺失值可根据业务含义选择删除、估算填补或保留缺失标记；异常值如不合理速度、重复记录、设备离线突变等应结合交通场景判断是真实事件还是采集错误；转换阶段应统一时间戳和统计粒度，统一坐标系、路段编号、站点或检测器编号，并完成单位换算和字段映射。(4 分)

(3) 存储与计算：海量原始轨迹、检测器和通行记录可存入 HDFS 或分布式文件系统，利用数据块和副本机制提高大文件存储能力与容错性；离线高峰流量统计、路段速度汇总等批处理任务可用 MapReduce；需要多轮迭代、交互查询或机器学习分析时，可利用 Spark 的内存计算和 DAG 调度提高效率。(4 分)

(4) 可视化报表：可用地图可视化展示路段速度和拥堵分布，用折线图展示早晚高峰速度、流量随时间变化，用柱状图或热力图比较不同路段、时段或方向的运行状态；“信”或准确原则要求图形变化真实反映数据变化，避免夸大比例；“达”或高效原则要求图表清晰、编码合适、便于快速读取；“雅”或美观原则要求布局和配色协调，但不能牺牲准确表达。(4 分)